

BettaFish 分支分析报告

概述

本报告分析了 `HKLHaoBin:BettaFish:feat-structured-merge-blocked` 分支相比 `main` 分支的新增功能和改进。

主要新增功能

1. 结构化上下文支持

实现方法

- 在多个引擎中添加 `structured_context` 字段
- 实现 `ContextCache` 持久化缓存
- 在 Streamlit 应用中添加结构化上下文展示标签页
- 集成 `StructuredContextBuilder` 用于构建上下文

相关文件和函数

文件修改:

- `MediaEngine/state.py`
- `QueryEngine/state.py`
- `InsightEngine/state.py`
- `agent.py`
- `context_display.py`

关键代码:

```
# 在 state.py 中添加 structured_context 字段
class State(BaseModel):
    structured_context: dict = Field(default_factory=dict)

# 在 agent.py 中集成 StructuredContextBuilder
self.structured_context_builder = StructuredContextBuilder()
```

2. 关键词标签器

实现方法

- 在 `contextualizer.py` 中添加关键词标签功能
- 新增 `keyword_labeler.py` 实现关键词标签功能
- 通过现有关键词优化配置为文本片段提供粗粒度语义标签
- 避免调用重量级 LLM，同时为多智能体工作流提供更丰富的事件元数据

相关文件和函数

新增文件:

- `keyword_labeler.py`

修改文件:

- `contextualizer.py`

关键函数:

- `_keyword_labeler_annotations()`: 在 `contextualizer.py` 中添加的方法
- `KeywordLabeler` 类: 在 `keyword_labeler.py` 中实现

关键代码:

```
# contextualizer.py
def _keyword_labeler_annotations(self, events):
    # 关键词标签处理逻辑
    return labeled_events

# keyword_labeler.py
```

```
class KeywordLabeler:
    def __init__(self, config):
        self.config = config

    def label_events(self, events):
        # 事件标签处理
        return labeled_events
```

3. 智能权重压缩算法

实现方法

- 在各引擎的 agent.py 中添加权重压缩逻辑
- 实现自适应事件修剪功能 (adaptive pruning)
- 引入最小 / 最大事件数量控制和基于阶段保留率的自适应算法
- 添加被抑制事件追踪功能
- 实现基于百分位数和中位值自适应阈值的事件保留机制

相关文件和函数

修改文件:

- InsightEngine/agent.py
- MediaEngine/agent.py
- QueryEngine/agent.py
- contextualizer.py

关键函数:

- adaptive_pruning(): 自适应事件修剪功能
- suppressed_events 追踪
- 基于阶段 (initial, reflection, default) 的保留率设置

关键代码:

```
# 在 agent.py 中添加权重压缩逻辑
def weight_compression(self, events):
    # 智能权重压缩算法实现
    return compressed_events

# 在 contextualizer.py 中实现自适应修剪
def adaptive_pruning(self, events, stage='default'):
    # 基于阶段的自适应修剪逻辑
    return pruned_events
```

4. 爬虫平台配置优化

实现方法

- 将平台配置从 'bili' 更改为 'zhihu'
- 关键词更新为 '影视飓风'
- 调整数据库配置参数
- 将数据保存选项从 'postgresql' 更改为 'db'
- 提高爬取数量限制从 5 到 50

相关文件和函数

修改文件:

- 配置文件（数据库配置）

关键代码:

```
# 配置文件修改
PLATFORM = 'zhihu'
KEYWORDS = '影视飓风'
SAVE_TO = 'db'
CRAWL_LIMIT = 50
```

5. 关键词标记器重构

实现方法

- 从远程 LLM 调用改为本地字典匹配
- 添加模糊匹配功能，支持使用 rapidfuzz 库进行近似字符串匹配
- 更新标签分类体系，定义了 30 个类别涵盖手工、美食、旅游等生活领域
- 优化关键词检测逻辑，支持直接匹配和模糊评分相结合的方式

相关文件和函数

修改文件:

- keyword_labeler.py

新增依赖:

- rapidfuzz 库

关键代码:

```
# 使用 rapidfuzz 进行模糊匹配
from rapidfuzz import fuzz
def fuzzy_match(self, text, keywords):
    scores = {}
    for keyword in keywords:
        score = fuzz.ratio(text, keyword)
        if score > self.threshold:
            scores[keyword] = score
    return scores
```

6. 日志输出优化

实现方法

- 修改 read_log_from_file 函数，增加 with_total 参数返回总行数
- 修改 get_output 函数，添加 tail 参数来限制返回的日志行数
- 在前端优化控制台显示，只展示新增的行避免重复显示
- 设置默认显示最近 500 行日志，最多可显示 2000 行

相关文件和函数

修改文件:

- 日志处理相关文件

关键函数:

- `read_log_from_file()`
- `get_output()`

关键代码:

```
def read_log_from_file(file_path, with_total=False):  
    # 读取日志文件并返回内容，支持返回总行数  
  
def get_output(tail=500):  
    # 获取最近 tail 行的日志输出
```

7. Docker 配置优化

实现方法

- 配置默认时区为 Asia/Shanghai
- 使用非交互模式安装依赖包，避免配置交互
- 添加 tzdata 时区数据包
- 系统时区文件链接设置
- 修正 libgdk-pixbuf 包名

相关文件和函数

修改文件:

- `Dockerfile`
- `docker-compose.yml`

关键代码:

```
# Dockerfile 中的时区配置
ENV TZ=Asia/Shanghai
RUN ln -snf /usr/share/zoneinfo/$TZ /etc/localtime && echo $TZ > /etc/timezone
RUN apt-get update && apt-get install -y tzdata
```

8. 系统重启功能

实现方法

- 在 `app.py` 中添加 `/api/system/restart` 端点
- 在前端添加重启按钮和确认弹窗

相关文件和函数

修改文件:

- `app.py`

关键代码:

```
# 在 app.py 中添加重启端点
@app.route('/api/system/restart', methods=['POST'])
def system_restart():
    # 系统重启逻辑实现
```

9. AI Agent 搜索功能增强

实现方法

- 在 InsightEngine、MediaEngine 和 QueryEngine 中添加无搜索结果处理，防止 AI 幻觉输出
- 更新 Bocha API 地址为国内访问更快的域名并增强对不同数据格式的兼容性
- 实现 WeasyPrint 自动安装机制，提升 PDF 输出依赖的可用性
- 优化前端配置界面的下拉选择功能及 XSS 防护
- 修复 ContextCache 的 JSON 序列化问题，增加 Set 类型处理

- 增加 Contentualizer 相关性过滤功能，提升搜索结果质量
- 优化数据库查询超时配置，提升稳定性

相关文件和函数

修改文件:

- 各引擎的 agent.py 文件

关键代码:

```
# 无搜索结果处理
if not search_results:
    # 处理无搜索结果的情况，防止AI幻觉输出
    return safe_response
```

总结

HKLHaoBin:BettaFish:feat-structured-merge-blocked 分支主要实现了以下核心功能:

- 结构化上下文管理系统** - 为多个引擎添加了结构化上下文支持，实现了上下文的持久化缓存和可视化展示
- 智能关键词标签系统** - 从远程 LLM 调用改为本地字典匹配，添加了模糊匹配功能，提高了标签效率
- 智能权重压缩算法** - 实现了自适应事件修剪和权重压缩，优化了上下文管理
- 系统优化和增强** - 包括日志输出优化、Docker 配置优化、系统重启功能等

这些改进显著提升了系统的性能、稳定性和用户体验，特别是在上下文管理和智能标签方面的创新实现。

(注：文档部分内容可能由 AI 生成)